

Modelo estocástico híbrido baseado em redes neurais não-tradicionais

-

Aluno: Edson Francisco Luque Mamani

24 de agosto de 2016

Sumário

1	Motivação	3
2	Objetivo	4

1 Motivação

Na teoria da probabilidade um Processo Estocástico se define como um conjunto de modelos que permitem o estudo de problemas com componentes aleatórias. Muitos problemas reais como previsão têm características não lineares e complexas, por vezes caótica, a fim de modelar o comportamento destes fenômenos, realizar uma aproximação linear pode gerar um modelo ineficiente [2] [10]. Ao observar esse tipo de fenômenos com características aleatórias por um período de tempo, consegue-se obter uma trajetória do processo observado. Ao realizar a mesma observação em um período de tempo diferente é possível obter outra trajetória, diferente da primeira. Um processo estocástico corresponde ao conjunto de todas as possíveis trajetórias que podem ser observadas desse fenômeno. Cada trajetória observada é chamada de série temporal. Portanto, uma série temporal é considerada uma realização de um processo estocástico.

A análise das séries temporais pode ser realizada por meio de modelos autorregressivos[4] dentro do qual destaca o modelo **PAR**(p)[11]. No entanto, estes modelos são estatísticos e lineares, o que significa que a sua aplicação em séries temporais de comportamento caótico (como as series hidrológicas) não pode capturar as características reais da série e portanto pode gerar resultados inconsistentes.

Entre as metodologias que tentam modelar problemas complexos não-lineares nos últimos anos as Redes Neurais Artificiais(**RNA**) destacam-se como métodos de aprendizado de máquina.([8],[5], [7]).

Na verdade, as **RNA's** do tipo feedforward na maioria das pesquisas e aplicações em modelos de previsão têm sido amplamente utilizados em contraste com as Redes Recorrentes[6]. As **RNA's** recorrentes são capazes de representar mapas não-lineares dinâmicos comumente encontrados nas tarefas de previsão de séries temporais[4]. Estudos sobre o desempenho deste tipo de redes neurais apresentam um desempenho melhor do que as **RNA's** feedforward em praticamente todos os testes[3]. Mas a principal razão para a preferência pela utilização das **RNA's** feedforward sobre as **RNA's** recorrentes é que a recorrência em rede neurais gera maior complexidade, especialmente no processo de treinamento da rede neural.

Isso motivou a elaboração de um modelo de processo estocástico utilizando Redes Neuronales Artificiales Recorrentes a fim de tomar vantagem das suas características acima mencionadas. Para tornar isso possível uma abordagem recentemente introduzido chamado Reservoir Computing (**RC**)[9] vai ser utilizado. O Reservoir Computing é uma abordagem de treino que está emergindo como simples e rápido em comparação com outras abordagens utilizadas nas **RNA's** recorrentes tradicionais, tudo isto a fim de reduzir a complexidade e aproveitar a sua capacidade comprovada para representar melhor as características das série temporais(hidrologicas).

Além disso, como parte do nosso modelo proposto será considerada um componente não-determinístico representando o ruído aleatório com uma distribuição normal, isso a fim de ter em conta a incerteza que normalmente afeta processos naturais[1]. Sendo este o nosso modelo uma nova proposta na literatura.

Escolheu-se, como estudo de caso, aplicar o modelo proposto no tratamento de afluências mensais sob o contexto do sistema hidrológico brasileiro.

2 Objetivo

Propor um modelo de processo estocástico para a geração de séries temporais sintéticas, igualmente prováveis à série histórica (previsão), utilizando técnicas de inteligência artificial relativamente novas **como Echo State Network (ESN)** e um ruído aleatório com base na incerteza que normalmente afeta tipos de problemas, como por exemplo os problemas que envolvem fenômenos climatológicos, econômicos, hidrológicos.

Referências

- [1] Awchi, Taymoor A and D K Srivastava (2004): Artificial Neural Network Model Application in Stochastic Generation of Monthly Streamflows for Mula Project.
- [2] BOX, G. G.; JENKINS (1970): Time series analysis: Forecasting and control.
- [3] Brezak, D.; T. Bacek; D. Majetic; J. Kasac; and B. Novakovic (March 2012): A comparison of feed-forward and recurrent neural networks in time series forecasting. In: *2012 IEEE Conference on Computational Intelligence for Financial Engineering Economics (CIFEr)*. pp. 1–6.
- [4] CAMPOS, LUCIANA CONCEICAO DIAS (2010): *PERIODIC STOCHASTIC MODEL BASED ON NEURAL NETWORKS*. PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO.
- [5] Cunge, Jean A. (2003): Of data and models. *Journal of Hydroinformatics*, 5(2):75–98.
- [6] de Vos, N. J. (2013): Echo state networks as an alternative to traditional artificial neural networks in rainfall runoff modelling. *Hydrology and Earth System Sciences*, 17(1):253–267.
- [7] de Vos, N. J. and T. H. M. Rientjes (2005): Constraints of artificial neural networks for rainfall-runoff modelling: trade-offs in hydrological state representation and model evaluation. *Hydrology and Earth System Sciences*, 9(1/2):111–126.
- [8] de Vos, N. J. and T. H. M. Rientjes (2008): Multiobjective training of artificial neural networks for rainfall-runoff modeling. *Water Resources Research*, 44(8):n/a–n/a. W08434.

- [9] Lukoševičius, Mantas and Herbert Jaeger (August 2009): Reservoir computing approaches to recurrent neural network training. *Computer Science Review*, 3(3):127–149.
- [10] Luna, Ivette; Rosangela Ballini; and Secundino Soares (09 2006): Técnicas identificacao de modelos lineares e no-lineares de séries temporais. *Sba: Controle e Automacao Sociedade Brasileira de Automatica*, 17:245 – 256.
- [11] MACEIRA, D. D. J. . D. J.M., M. E. P. ; PENNA (2005): Geracao de cenarios sinteticos de energia e vazao para o planejamento da operacao energética. *In: XVI SIMPoSIO BRASILEIRO DE RECURSOS HídRICOS*,.